

Adaptación de Dominio Cross-Modal Débilmente Supervisada para la Segmentación de Miomas Uterinos


Segmentación de miomas en ultrasonido mediante transferencia de conocimiento entre modalidades

Daira Iliana Orlandini
Presentación de Trabajo Final de Grado (TFG)

AGENDA


Problema	3
Propuesta	4–5
Metodología	6–9
Resultados	10–11
Conclusiones	12–13
Trabajos futuros	14

Motivación y problema



Problema Clínico

- Los miomas uterinos son los tumores benignos **más frecuentes** en mujeres.
- Entre el **70 %** y el **80 %** de las mujeres desarrollarán miomas **antes de los 50 años** [2].
- El ultrasonido constituye la modalidad de primera elección para la evaluación clínica [3].



Necesidad

¿Es posible segmentar automáticamente miomas en ultrasonido?



Problema Técnico

- La segmentación supervisada requiere máscaras píxel a píxel.
- Los datasets públicos de ultrasonido con segmentaciones densas son escasos.
- Existen datasets de RM con anotaciones realizadas por expertos. [16]



Idea


¿Cómo aprovechar el conocimiento aprendido en RM para segmentar miomas en ultrasonido utilizando únicamente anotaciones débiles?

Propuesta



¿Qué tengo?

- RM con máscaras de segmentación realizadas por expertos.
- US con anotaciones débiles mediante bounding boxes.



Estrategia propuesta

- Aprender representaciones morfológicas en RM.
- Transferir ese conocimiento hacia US.
- Utilizar las bounding boxes como supervisión débil.

Objetivo

Desarrollar un modelo capaz de segmentar miomas uterinos en ultrasonido mediante **Adaptación de Dominio Débilmente Supervisada**.

¿CÓMO ABORDAMOS ESTE PROBLEMA?

ADAPTACIÓN DE DOMINIO DÉBILMENTE SUPERVISADA

Weakly Supervised Domain Adaptation (WDA)

Combina la transferencia de conocimiento desde un dominio completamente anotado con información parcial disponible en el dominio objetivo, reduciendo la necesidad de anotaciones densas.

En este trabajo, las *bounding boxes* en ultrasonido proporcionan restricciones espaciales que guían el aprendizaje de la segmentación.




Ventaja

Transferir representaciones morfológicas aprendidas en RM hacia imágenes de ultrasonido utilizando supervisión débil basada en *bounding boxes*.

Preprocesamiento Dominio Fuente (RM)

Dominio Fuente RM
Máscaras completas


Imagen original



Máscara



Superposición



UMD Dataset


- Dataset público de la University of Maryland (UMD)
- 300 pacientes
- 6845 cortes originales
- Máscaras validadas por expertos

- Reorientación anatómica
- Normalización
- Remuestreo a 0.8 mm/píxel
- Estandarización a 256×256

Preprocesamiento Dominio Objetivo (US)

Dominio Objetivo US
Bounding Boxes

US Original → Bounding Box



Uterine Fibroid Ultrasound Images (Yang, 2023)

- 288 imágenes seleccionadas manualmente
- Bounding boxes
- Cortes sagitales transvaginales

- Eliminación de artefactos
- Extracción del cono acústico
- Normalización
- Remuestreo a 0.8 mm/píxel
- Estandarización a 256×256



Arquitectura propuesta

Attention U-Net


- Diseñada para tareas de segmentación semántica.
- Combina información contextual y espacial mediante una estructura encoder-decoder.
- Los Attention Gates permiten resaltar regiones anatómicamente relevantes y reducir activaciones provenientes del fondo. [14]

Características principales

- Entrada: imágenes monocanal de 256×256 píxeles.
- Encoder-decoder con skip connections.
- Attention Gates en cada conexión de salto.
- Salida binaria: mioma / fondo.




Estrategia de Entrenamiento



Etapa 1: Preentrenamiento Supervisado en RM

Aprender representaciones morfológicas de los miomas utilizando máscaras completas.

- Dataset RM completamente anotado.
- BCE + Dice Loss.
- Optimización mediante Adam.



Etapa 2: Adaptación al Dominio US

Transferir el conocimiento aprendido hacia ultrasonido.


- Supervisión fuerte en RM.
- Supervisión débil en US mediante bounding boxes.
- Restricciones espaciales para guiar la segmentación.

Aprendizaje de representaciones (preentrenamiento)

Transferencia de conocimiento

Resultados Adaptacion RM → US

Transfereencia
de
conocimiento





Dominio US

Estrategia	bbox_in	Centroid	Score
DANN + bbox débil	0.4774	0.5438	—
Soft-bbox inicial	0.543	0.5563	0.6742
Soft-bbox final	0.6409	0.7	0.7541

+34% bbox_in respecto a DANN


Resultados Adaptacion RM → US



US PROCESADO

MÁSCARA
PRE POSTPROCESSING

MÁSCARA POSTPROCESSING



Desempeño sobre Ultrasonido

1

Las representaciones aprendidas en RM son transferibles

2

Las bounding boxes aportan información útil

3

La segmentación sigue siendo un desafío

Hallazgo principal

La localización de miomas es factible mediante transferencia RM→US, aunque la delimitación precisa de contornos continúa siendo limitada por el cambio de dominio.

Conclusiones

- ✓ Se implementó un esquema WDA para segmentación de miomas.
- ✓ Las representaciones aprendidas en RM fueron transferibles a US.
- ✓ Las bounding boxes permitieron guiar la adaptación.
- ✓ Soft-bbox obtuvo la mejor localización.

bbox_in = 0.6409
centroid_in = 0.70

Trabajos Futuros

- Incrementar el tamaño del dataset objetivo.
- Incorporar máscaras anotadas por especialistas.
- Pseudoetiquetado iterativo.
- Transferencia de contornos finos RM→US.
- Análisis por tipos de mioma (FIGO).

¿Preguntas?