

Adaptación de Dominio Cross-Modal Débilmente Supervisada para la Segmentación de Miomas Uterinos

Daira Iliana Orlandini

Resumen—Este trabajo presenta un modelo de segmentación semántica binaria de miomas uterinos en ultrasonido 2D mediante transferencia de conocimiento desde un dominio origen de Resonancia Magnética (RM) hacia un dominio destino de ultrasonido. Para ello, se emplea una arquitectura Attention U-Net preentrenada de forma supervisada utilizando imágenes de RM con anotaciones pixel a pixel. Posteriormente, se investiga una estrategia de Adaptación de Dominio Débilmente Supervisada (WDA), donde las imágenes ecográficas disponen únicamente de anotaciones de localización mediante *bounding boxes*. Con el fin de reducir las diferencias entre modalidades, ambos dominios son sometidos a un proceso de estandarización geométrica e isométrica a 0,8 mm/píxel. Los experimentos realizados permiten analizar el potencial y las limitaciones de la transferencia de conocimiento entre modalidades para la localización y segmentación de miomas uterinos en ultrasonido. Los resultados preliminares sugieren que las representaciones aprendidas en RM pueden contribuir a la identificación de regiones anatómicamente plausibles en imágenes ecográficas; sin embargo, la recuperación completa de los contornos continúa representando un desafío. Estos hallazgos permiten evaluar el potencial de la Adaptación de Dominio Débilmente Supervisada como estrategia para reducir la dependencia de anotaciones densas en imágenes de ultrasonido.

Index Terms—Segmentación de miomas uterinos, ultrasonido transvaginal, resonancia magnética, aprendizaje profundo, Attention U-Net, adaptación de dominio débilmente supervisada, supervisión débil, transferencia de conocimiento, transferencia cross-modal.

I. INTRODUCCIÓN

Los miomas uterinos, conocidos también como leiomiomas o fibromas, son los tumores benignos más frecuentes en las mujeres [1]. Se estima que para las mujeres que alcanzan los 50 años, la incidencia de esta patología se sitúa entre el 70 % y el 80 % [2]. Aunque una parte considerable de los casos son asintomáticos, aproximadamente el 30 % de las mujeres afectadas presenta síntomas clínicos que impactan profundamente su bienestar general [1].

El diagnóstico por ultrasonido (US) representa la modalidad de primera elección en la evaluación clínica ante la sospecha de patologías ginecológicas, debido a que está ampliamente disponible, es una alternativa económica y clínicamente segura [3]. Por otro lado, la resonancia magnética (RM) tiene un alto rendimiento diagnóstico en la visualización de miomas, y se recomienda como el método de elección para la evaluación precisa de los miomas. Sin embargo, la RM es una técnica costosa, lo que hace necesario que su uso se limite a situacio-

nes en las que supere claramente al ultrasonido transvaginal [4].

El desarrollo de sistemas de asistencia al diagnóstico (CAD) para la segmentación de miomas ha sido un área de investigación activa. En la literatura actual, existen diversas soluciones de segmentación semántica aplicadas a modalidades de ultrasonido y resonancia magnética, donde se implementan redes neuronales profundas para mejorar la precisión diagnóstica [1], [5].

Aunque se han desarrollado múltiples enfoques de segmentación automática para imágenes médicas, la segmentación de miomas uterinos en ultrasonido 2D continúa siendo una tarea desafiante debido a factores inherentes a esta modalidad, como el ruido speckle, el bajo contraste y la variabilidad en la apariencia de las lesiones. Estas características dificultan la delimitación precisa de los miomas y pueden afectar el desempeño de los modelos de segmentación automática. Asimismo, las diferencias existentes entre las imágenes de resonancia magnética y ultrasonido generan una brecha de dominio (*domain shift*) que dificulta la transferencia directa de modelos entre modalidades [6].

El objetivo de este trabajo es desarrollar un modelo de segmentación semántica binaria de miomas uterinos en ultrasonido 2D, basado en una arquitectura Attention U-Net y un esquema de Adaptación de Dominio Débilmente Supervisada (WDA), que permita transferir representaciones morfológicas aprendidas en RM hacia imágenes ecográficas. Mientras que el dominio fuente dispone de máscaras de segmentación pixel a pixel, el dominio destino únicamente cuenta con anotaciones débiles basadas en *bounding boxes*. En este contexto, se investiga el potencial de combinar transferencia de conocimiento entre modalidades y adaptación de dominio débilmente supervisada para la localización y segmentación de miomas uterinos en ultrasonido.

II. ESTADO DEL ARTE

A continuación, se presenta una revisión de la literatura reciente. En primer lugar, se examinan los avances en la segmentación de miomas uterinos mediante técnicas de aprendizaje profundo. Posteriormente, se analizan estrategias de transferencia de conocimiento y adaptación de dominio aplicadas a imágenes médicas.

Pan *et al.* [1] introdujeron el *Uterine Myoma MRI Dataset* (UMD), la base de datos pública de RM uterina más extensa

hasta la fecha, con 300 pacientes y anotaciones validadas según la clasificación FIGO. Su enfoque de segmentación de instancias en imágenes T2WI no solo delimita miomas, sino que integra la identificación de la pared muscular y quistes para reconstrucciones 3D. Este trabajo establece un estándar de referencia para la validación de modelos inteligentes, evidenciando que el uso de grandes volúmenes de datos en RM permite una precisión comparable a la de expertos clínicos.

Saleem *et al.* [7] evaluaron el rendimiento de la arquitectura nnU-Net para la segmentación automatizada de miomas uterinos en imágenes de RM. El estudio destaca la capacidad de las CNN para gestionar la variabilidad morfológica de los tumores, alcanzando un coeficiente Dice de 0.82. Los autores concluyen que, aunque las CNN superan los métodos tradicionales, la precisión de la segmentación sigue siendo altamente sensible a la calidad de la imagen y a la distinción entre el mioma y el miometrio circundante.

Xu *et al.* [8] introdujeron HilbertMamba (LGRNet) para la segmentación de miomas en ultrasonido dinámico, abordando el ruido acústico y las fronteras difusas. La arquitectura combina *Cyclic Neighborhood Propagation* para el contexto temporal local y *Hilbert Selective Scan* (Mamba) para capturar dependencias globales mediante curvas de Hilbert. Utilizando el dataset UFUV de 100 videos, LGRNet superó a los métodos del estado del arte en precisión y robustez, estableciendo un referente para la segmentación de miomas en ultrasonido.

Zhang *et al.* [5] propusieron HIFUNet para la segmentación multiclase de útero, miomas y columna vertebral en RM, optimizando la planificación de tratamientos HIFU. La arquitectura emplea un *backbone* ResNet101 integrado con un módulo de Red Convolutiva Global (GCN) de núcleos grandes (11x11) para capturar el contexto anatómico global y un bloque de Convoluciones Atrous Múltiples Profundas (DMAC) para extraer características multiescala. Validado con 297 pacientes, HIFUNet superó a la Attention U-Net y U-Net estándar, logrando un rendimiento comparable al de expertos clínicos en la delimitación de estructuras críticas.

Inbaraj *et al.* [9] introdujeron una estrategia de aprendizaje por transferencia *cross-modal* que explota representaciones compartidas entre múltiples modalidades médicas. Los autores evaluaron la transferencia de conocimiento entre distintas modalidades, incluyendo RM y US, demostrando que este enfoque puede mejorar significativamente el rendimiento de modelos entrenados en escenarios con disponibilidad limitada de datos anotados.

Xu *et al.* [10] propusieron Box-Adapt, uno de los primeros marcos de Adaptación de Dominio Débilmente Supervisada (WDA) para segmentación médica utilizando anotaciones basadas en *bounding boxes*. El método combina transferencia de conocimiento entre dominios mediante redes con pesos compartidos y un esquema de aprendizaje *Positive-Unlabeled* (PU) que permite aprovechar la información parcial proporcionada por las cajas delimitadoras. Además, incorpora una etapa de autoentrenamiento con pseudoetiquetas refinadas mediante restricciones espaciales derivadas de las *bounding*

boxes. Los resultados obtenidos muestran que la incorporación de anotaciones débiles en el dominio objetivo puede reducir significativamente la brecha de rendimiento existente entre los enfoques de adaptación de dominio no supervisada y los métodos completamente supervisados.

Al analizar estos trabajos de manera conjunta, se observa una evolución desde arquitecturas convolucionales convencionales hacia modelos capaces de integrar mecanismos de atención, aprendizaje multiescala y transferencia de conocimiento entre modalidades. Mientras que los estudios basados en RM, como los de Zhang *et al.* y el dataset UMD, han alcanzado una madurez técnica notable en la segmentación de miomas uterinos, la literatura en ultrasonido continúa enfrentando desafíos asociados al ruido acústico, el bajo contraste y la variabilidad anatómica. Asimismo, trabajos recientes como los de Inbaraj *et al.* y Xu *et al.* evidencian que la transferencia de conocimiento *cross-modal* y la Adaptación de Dominio Débilmente Supervisada constituyen estrategias prometedoras para reducir la dependencia de anotaciones densas. Sin embargo, la aplicación de estos enfoques al problema específico de la segmentación de miomas uterinos mediante transferencia entre resonancia magnética y ultrasonido continúa siendo limitada. En particular, existe escasa evidencia sobre el uso combinado de representaciones anatómicas aprendidas en RM y anotaciones débiles basadas en *bounding boxes* para la segmentación de miomas en US. El presente trabajo busca contribuir en esta dirección mediante un esquema de Adaptación de Dominio Débilmente Supervisada basado en una arquitectura Attention U-Net.

III. MARCO TEÓRICO

La segmentación semántica se define como el proceso de asignar una o múltiples etiquetas de categoría a cada píxel de una imagen. El objetivo principal es dividir la imagen en regiones semánticamente coherentes, de manera que todos los píxeles pertenecientes a una misma estructura compartan la misma etiqueta [11]. Debido a esta naturaleza de clasificación a nivel de píxel, la segmentación semántica se considera una tarea de etiquetado denso (*dense labeling*), permitiendo una comprensión detallada del contenido visual en comparación con problemas más generales como la clasificación de imágenes o la detección de objetos [12]. En imágenes biomédicas, esta técnica resulta fundamental para la localización y delimitación automática de órganos, vasos sanguíneos y tumores, facilitando la obtención de mediciones cuantitativas que pueden apoyar el diagnóstico y la planificación terapéutica [11].

El avance reciente de la segmentación médica se encuentra estrechamente ligado al desarrollo de arquitecturas basadas en redes neuronales convolucionales. Entre ellas, la U-Net propuesta por Ronneberger *et al.* [13] se ha consolidado como una de las arquitecturas más influyentes debido a su capacidad para combinar información contextual y espacial mediante una estructura codificador-decodificador. La red utiliza conexiones de salto (*skip connections*) que transfieren características de alta resolución desde el codificador hacia el decodificador, per-

mitiendo recuperar detalles espaciales que se pierden durante las operaciones de reducción de resolución.

Sin embargo, las conexiones de salto convencionales transfieren indiscriminadamente tanto información relevante como características asociadas al fondo de la imagen. Como señalan Oktay *et al.* [14], esta transferencia puede introducir activaciones irrelevantes provenientes de regiones de fondo, afectando la capacidad de la red para localizar con precisión estructuras anatómicas de interés. En aplicaciones médicas, donde los órganos o lesiones suelen ocupar una pequeña porción de la imagen y presentan una alta variabilidad anatómica, este problema puede favorecer la aparición de falsos positivos y dificultar la delimitación precisa de las regiones objetivo. Con el propósito de abordar esta limitación, los mismos autores introdujeron la arquitectura Attention U-Net, incorporando mecanismos de atención directamente en las conexiones de salto [14].

Las denominadas *Attention Gates* utilizan una señal de guía proveniente de niveles más profundos de la red para calcular coeficientes de atención espaciales que modulan la información transmitida por cada conexión de salto. A diferencia de mecanismos de atención globales, este enfoque genera coeficientes locales que permiten a la red focalizarse dinámicamente en regiones anatómicamente relevantes mientras atenúa activaciones asociadas al fondo o al ruido. Como resultado, la arquitectura aprende implícitamente dónde concentrar su atención durante la segmentación, mejorando la sensibilidad y el coeficiente Dice sin introducir una sobrecarga computacional significativa [14].

A pesar del éxito alcanzado por este tipo de arquitecturas en imágenes médicas, la generalización entre diferentes modalidades de adquisición continúa representando un desafío importante. Las diferencias existentes entre resonancia magnética y ultrasonido generan distribuciones de datos considerablemente distintas debido a variaciones en resolución espacial, contraste tisular, ruido y artefactos de adquisición. Este fenómeno, conocido como *domain shift*, provoca que modelos entrenados sobre una modalidad experimenten una degradación significativa de rendimiento cuando son aplicados directamente sobre otra [6].

Para abordar este problema han surgido las técnicas de Adaptación de Dominio (*Domain Adaptation*), cuyo objetivo consiste en transferir conocimiento desde un dominio fuente hacia un dominio objetivo minimizando las discrepancias entre ambas distribuciones. En este contexto surge el paradigma de Adaptación de Dominio Débilmente Supervisada (WDA, *Weakly-Supervised Domain Adaptation*), introducido formalmente por Paul *et al.* [15] y posteriormente extendido al ámbito médico por Xu *et al.* [10]. Este enfoque combina la transferencia de conocimiento desde un dominio completamente anotado con información parcial disponible en el dominio objetivo, permitiendo reducir significativamente el costo de anotación sin renunciar completamente a la supervisión humana.

Entre las distintas formas de supervisión débil, las anotaciones mediante *bounding boxes* representan una alternativa

particularmente atractiva debido a su bajo costo de generación en comparación con las máscaras de segmentación píxel a píxel. Mientras que una máscara requiere delinear con precisión toda la estructura anatómica, una *bounding box* únicamente proporciona información aproximada sobre su localización espacial [15]. Diversos trabajos han demostrado que estas anotaciones pueden utilizarse para imponer restricciones geométricas, generar pseudoetiquetas o guiar mecanismos de atención, permitiendo entrenar modelos de segmentación con una reducción sustancial del esfuerzo de anotación.

IV. METODOLOGÍA

El marco de trabajo propuesto aborda la segmentación de miomas uterinos mediante un enfoque de Adaptación de Dominio Débilmente Supervisada (Weakly Supervised Domain Adaptation, WDA). El objetivo es transferir el conocimiento morfológico aprendido a partir de un dominio origen etiquetado $\mathcal{D}_S = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$, correspondiente a imágenes de Resonancia Magnética (RM) con máscaras de segmentación densas, hacia un dominio objetivo $\mathcal{D}_T = \{(x_j^t, b_j^t)\}_{j=1}^{n_t}$, compuesto por imágenes de ultrasonido (US) que disponen únicamente de anotaciones débiles mediante *bounding boxes*. El flujo metodológico se estructura en dos etapas principales: la homogeneización de ambos dominios en un espacio geométrico común y el entrenamiento de un modelo capaz de combinar supervisión fuerte en RM con supervisión débil en US.

IV-A. Adquisición y Preprocesamiento de Datos

La adquisición del dataset fuente $\mathcal{D}_S$ proviene del compendio de datos públicos de RM ‘*UMD: Uterine Myoma MRI Dataset*’ [16], el cual abarca 300 volúmenes de pacientes y 6,845 cortes (*slices*) en formato NIfTI con anotaciones validadas por expertos. El conjunto de datos destino $\mathcal{D}_T$ corresponde a ‘*Uterine fibroid ultrasound images*’ (Versión 2) [17], compuesto originalmente por 871 imágenes ecográficas en formato PNG/JPG que presentan variabilidad en sus dimensiones nativas debido a diferencias en los parámetros de adquisición médica.

Dado que el objetivo de este trabajo es la segmentación de miomas uterinos en imágenes de ultrasonido transvaginal, se realizó un proceso de selección manual del conjunto de datos. Se excluyeron imágenes correspondientes a mujeres embarazadas, vistas anatómicas no compatibles con el protocolo de preprocesamiento propuesto y estudios con niveles elevados de ruido o artefactos que impedían la correcta identificación de las estructuras de interés. Asimismo, se conservaron únicamente imágenes correspondientes a cortes sagitales. Como resultado de este proceso de curación del conjunto de datos, el dominio objetivo quedó conformado por 288 imágenes de ultrasonido transvaginal.

A diferencia del dominio fuente, las imágenes de ultrasonido no disponen de máscaras de segmentación píxel a píxel, sino únicamente de anotaciones débiles basadas en *bounding boxes*, las cuales delimitan de manera aproximada la región donde se encuentra el mioma.

IV-A1. Estandarización del Dominio Origen (RM): El preprocesamiento de las imágenes de resonancia magnética se realizó mediante un pipeline diseñado para garantizar consistencia anatómica, resolución física uniforme y ausencia de fuga de información entre particiones.

1. **Partición por paciente:** La división entrenamiento-validación-prueba se realizó a nivel de paciente antes de la extracción de cortes bidimensionales, evitando fuga de información entre conjuntos.
2. **Reorientación anatómica:** Los volúmenes NIfTI fueron transformados al sistema de coordenadas canónico RAS+ mediante NiBabel [18], garantizando una orientación anatómica consistente.
3. **Extracción de cortes sagitales:** Se extrajeron cortes 2D a lo largo del eje sagital del volumen canonizado.
4. **Filtrado de cortes:** Se descartaron cortes cuya máscara segmentada presentara un área menor a 150 píxeles, eliminando muestras con escasa información lesional.
5. **Normalización de intensidad:** Las intensidades de cada corte se normalizaron de forma independiente al rango $[0, 1]$ mediante escalamiento Min-Max.
6. **Remuestreo físico:** Las imágenes y máscaras fueron remuestreadas a una resolución uniforme de 0,8 mm/píxel. Se utilizó interpolación bicúbica para las imágenes y vecino más cercano para las máscaras.
7. **Estandarización espacial:** Todas las muestras fueron ajustadas a un tamaño fijo de 256×256 píxeles mediante recorte central o relleno con ceros, preservando la resolución física previamente establecida.

Como resultado del proceso de preprocesamiento y filtrado, el conjunto final utilizado en los experimentos quedó conformado por 2629 cortes para entrenamiento, 298 para validación y 287 para prueba, totalizando 3214 pares imagen-máscara. Estas muestras corresponden únicamente a cortes sagitales que contenían información lesional suficiente según los criterios de selección establecidos.

IV-A2. Estandarización del Dominio Destino (US): Las imágenes de US fueron sometidas a un proceso de homogeneización geométrica y radiométrica para reducir la variabilidad asociada a diferentes equipos, campos de visión y condiciones de adquisición.

1. **Eliminación de artefactos:** Se removieron textos, marcadores y elementos superpuestos mediante umbralización adaptativa, operaciones morfológicas e *inpainting* basado en el método de Telea [19].
2. **Extracción de la región de interés:** Se identificó y recortó el cono acústico útil, eliminando regiones externas sin información anatómica relevante.
3. **Remuestreo físico:** Las imágenes fueron reescaladas a una resolución uniforme de 0,8 mm/píxel utilizando la información del campo de visión (FOV).
4. **Normalización de intensidad:** Se aplicó normalización robusta basada en percentiles calculados sobre los píxeles válidos de la imagen, excluyendo el fondo negro, seguida de un escalamiento al rango $[0, 1]$.

5. **Estandarización espacial:** Todas las imágenes fueron proyectadas sobre un lienzo de 256×256 píxeles mediante *padding* o recorte central según correspondiera.
6. **Alineación anatómica:** Las imágenes fueron rotadas y reflejadas para aproximar su orientación anatómica a la utilizada en el dominio RM.
7. **Transformación de anotaciones:** Las coordenadas de las *bounding boxes* fueron transformadas mediante las mismas operaciones geométricas aplicadas a cada imagen, preservando la correspondencia espacial entre imagen y anotación.

Tras el proceso de selección, preprocesamiento y partición del conjunto de datos, el dominio objetivo quedó conformado por 288 imágenes de ultrasonido transvaginal con sus correspondientes anotaciones mediante *bounding boxes*. De ellas, 230 fueron destinadas al entrenamiento, 29 a validación y 29 a prueba.

IV-B. Arquitectura del Modelo

Como modelo base se empleó una arquitectura Attention U-Net para segmentación semántica binaria. La red recibe como entrada imágenes monocanal de 256×256 píxeles y produce un mapa de logits de igual dimensión asociado a la región correspondiente al mioma.

La arquitectura sigue un esquema encoder-decoder derivado de U-Net. El encoder está compuesto por cuatro niveles de extracción jerárquica de características mediante bloques convolucionales formados por dos convoluciones 3×3 , normalización por lotes (*Batch Normalization*) y funciones de activación ReLU. El número de filtros aumenta progresivamente desde 64 hasta 512 canales, mientras que el bloque *bottleneck* alcanza una profundidad de 1024 canales.

El decoder reconstruye gradualmente la resolución espacial mediante convoluciones transpuestas y conexiones de salto (*skip connections*) provenientes de los niveles correspondientes del encoder. Antes de cada concatenación, las características transferidas son filtradas mediante mecanismos de atención (*Attention Gates*), los cuales utilizan información contextual del decoder para resaltar regiones anatómicamente relevantes y reducir la influencia de estructuras no asociadas al mioma. La Figura 1 presenta un esquema general de la arquitectura utilizada en este trabajo.

La capa de salida consiste en una convolución 1×1 que genera un mapa de logits asociado a la región correspondiente al mioma. La función sigmoide se aplica posteriormente para obtener probabilidades.

De forma complementaria, se implementó una variante experimental compatible con adaptación adversarial de dominio basada en *Domain-Adversarial Neural Networks* (DANN). No obstante, esta configuración no fue utilizada en la evaluación final, donde se empleó exclusivamente la arquitectura Attention U-Net.




Figura 1. Arquitectura Attention U-Net utilizada en este trabajo. La red emplea una estructura encoder-decoder con conexiones de salto filtradas mediante mecanismos de atención (AG), permitiendo resaltar regiones anatómicamente relevantes antes de cada concatenación en el decoder.

IV-C. Estrategia de Entrenamiento

El entrenamiento del modelo se organizó en dos etapas principales. En primer lugar, se realizó un preentrenamiento supervisado sobre imágenes de RM, dominio para el cual se disponía de máscaras completas de segmentación. Posteriormente, el modelo preentrenado se utilizó como punto de partida para la adaptación al dominio de US, donde las anotaciones disponibles correspondían a *bounding boxes* y no a máscaras píxel a píxel.

IV-C1. Preentrenamiento supervisado en RM: En la primera etapa se entrenó la arquitectura Attention U-Net utilizando únicamente cortes sagitales de RM previamente procesados y estandarizados a 256×256 píxeles. Cada muestra de entrenamiento estuvo compuesta por una imagen monocanal y su máscara binaria correspondiente al mioma.

El objetivo de esta etapa fue que la red aprendiera representaciones morfológicas asociadas a la localización y delimitación de miomas a partir de supervisión fuerte. Para ello, se empleó

una función de pérdida combinada entre *Binary Cross Entropy with Logits* y pérdida Dice. La entropía cruzada binaria permitió optimizar la clasificación píxel a píxel, mientras que la pérdida Dice favoreció el solapamiento global entre la predicción y la máscara de referencia.

Durante el entrenamiento, el modelo produjo logits sin normalizar. La función sigmoide se aplicó para obtener probabilidades en el término Dice y para el cálculo de métricas. La optimización se realizó mediante Adam, con una tasa de aprendizaje inicial de 1×10^{-4} y un esquema de reducción de la tasa de aprendizaje basado en el desempeño de validación.

Al finalizar cada época, el modelo fue evaluado sobre el conjunto de validación RM utilizando Dice, HD95 y *Object Precision*. El checkpoint con mejor desempeño de validación fue utilizado posteriormente como inicialización para la etapa de adaptación al dominio de ultrasonido.

IV-C2. Adaptación al dominio de ultrasonido: En la segunda etapa, el modelo preentrenado en RM se utilizó como iniciali-

zación para adaptar la segmentación al dominio de ultrasonido. Esta etapa fue necesaria debido a las diferencias existentes entre ambas modalidades, ya que las imágenes de RM presentan estructuras anatómicas más definidas, mientras que las imágenes ecográficas contienen ruido speckle, artefactos de adquisición y menor contraste de bordes.

Durante esta fase se entrenó el modelo de manera conjunta con dos tipos de datos. Por un lado, se continuó utilizando RM con máscaras completas, manteniendo una señal de supervisión fuerte que evitara la degradación de la capacidad segmentadora previamente aprendida. Por otro lado, se incorporaron imágenes de US con anotaciones débiles en forma de *bounding boxes*.

Dado que las *bounding boxes* no representan una máscara exacta de la lesión, no fueron utilizadas como referencia píxel a píxel. En su lugar, se diseñó una función de supervisión débil basada en restricciones espaciales, inspirada en enfoques de segmentación mediante anotaciones de localización reportados en la literatura [15], [10]. Esta función penaliza activaciones fuera de la región delimitada por la anotación, favorece la presencia de predicción dentro de la caja y regula el tamaño de la región segmentada para evitar soluciones degeneradas.

La función objetivo de adaptación puede resumirse como:

$$\mathcal{L}_{total} = \lambda_{RM}\mathcal{L}_{RM} + \lambda_{US}\mathcal{L}_{US}^{weak}$$

donde $\mathcal{L}_{RM}$ corresponde a la pérdida supervisada calculada sobre imágenes de RM con máscaras completas, mientras que $\mathcal{L}_{US}^{weak}$ representa la pérdida de supervisión débil aplicada sobre las imágenes de US.

En la configuración final no se empleó pérdida adversarial de dominio, por lo que el entrenamiento se basó exclusivamente en la combinación de supervisión fuerte en RM y supervisión débil en US.

Durante la adaptación, las épocas se definieron en función del conjunto de US, utilizando ciclos del conjunto RM para mantener la supervisión fuerte sin sobrerepresentar excesivamente el dominio fuente. El modelo fue evaluado tanto sobre validación RM como mediante métricas débiles en US. Para RM se conservaron Dice, HD95 y *Object Precision*; para US se evaluó la coherencia espacial de la predicción respecto a la *bounding box*, incluyendo la proporción de máscara dentro de la caja, la superposición con la anotación, la ubicación del centroide y la relación de área predicha.

Finalmente, la selección del mejor checkpoint de adaptación no se basó únicamente en el desempeño sobre RM, sino en un puntaje compuesto orientado al dominio objetivo. Este criterio combinó métricas de localización y consistencia espacial en US junto con el desempeño de segmentación en RM. Debido a la ausencia de máscaras densas en el dominio objetivo, este enfoque permitió seleccionar modelos que conservaran la capacidad segmentadora aprendida en RM y, simultáneamente, mejoraran la localización anatómica de la lesión en ultrasonido.

IV-D. Inferencia y Postprocesamiento

Una vez concluida la etapa de adaptación, el mejor modelo seleccionado fue utilizado para generar predicciones sobre imágenes de ultrasonido previamente estandarizadas. Durante la inferencia se empleó únicamente el módulo segmentador basado en Attention U-Net, utilizando los parámetros almacenados en el checkpoint seleccionado según el criterio de evaluación descrito anteriormente.

Las predicciones obtenidas fueron posteriormente sometidas a una etapa de postprocesamiento orientada a mejorar su coherencia espacial y reducir activaciones espurias características de las imágenes ecográficas.

IV-D1. Generación de Predicciones: Cada imagen de ultrasonido fue representada como una entrada monocanal de tamaño 256×256 píxeles. La red produjo un mapa de logits de igual resolución espacial, el cual fue transformado en probabilidades mediante la función sigmoide.

Posteriormente, las probabilidades fueron binarizadas utilizando un umbral fijo de 0.35. Este valor fue seleccionado empíricamente a partir de experimentos preliminares e inspección visual de las predicciones, ya que proporcionó un equilibrio adecuado entre sensibilidad de detección y fragmentación de las máscaras segmentadas.

Los píxeles con probabilidad superior al umbral fueron asignados a la clase mioma, obteniéndose una máscara binaria inicial. Adicionalmente, se conservaron los mapas de probabilidad para la inspección cualitativa de los resultados.

IV-D2. Postprocesamiento de Predicciones: Con el objetivo de reducir falsas detecciones y mejorar la consistencia anatómica de las segmentaciones, se aplicó una etapa de postprocesamiento sobre las máscaras binarias generadas por el modelo.

Inicialmente se identificaron las distintas regiones segmentadas presentes en la predicción. Las regiones de área reducida fueron eliminadas mediante un criterio de tamaño mínimo, aunque podían conservarse cuando presentaban intersección con la *bounding box* disponible o con una versión expandida de la misma.

Cuando existían múltiples regiones candidatas, se seleccionó una única componente final. Si una o más regiones intersectaban la *bounding box* expandida, se conservó aquella con mayor superposición espacial. En caso contrario, se seleccionó la región cuyo centroide se encontraba más próximo al centro de la anotación.

Sobre la componente seleccionada se aplicó posteriormente una operación de cierre morfológico seguida de relleno de huecos internos. Finalmente, se conservó únicamente la componente conexas principal.

Es importante destacar que las *bounding boxes* no fueron utilizadas como máscaras duras ni como mecanismo de recorte directo de las predicciones. Su función consistió exclusivamente en proporcionar información espacial para orientar la

selección de la región anatómicamente más plausible durante el postprocesamiento.

V. EXPERIMENTOS Y RESULTADOS

V-A. Desempeño en Resonancia Magnética

En la primera etapa se evaluó el desempeño de la arquitectura Attention U-Net entrenada de forma supervisada sobre el dominio RM. El mejor checkpoint del preentrenamiento se obtuvo en la época 25, utilizando como criterio de selección el coeficiente Dice calculado sobre el conjunto de validación.

El modelo alcanzó un Dice de validación de 0.9126, un HD95 de 5.04 píxeles y una *Object Precision* de 0.9567. Estos resultados indican un elevado grado de solapamiento entre las máscaras predichas y las máscaras de referencia, así como una adecuada capacidad para detectar correctamente lesiones individuales.

Cuadro I
DESEMPEÑO DEL MODELO PREENTRENADO EN RM.

Modelo	Época	Dice	HD95 (px)	Object Precision
Attention U-Net	25	0.9126	5.04	0.9567

La Figura 2 presenta un ejemplo representativo de segmentación obtenido durante la etapa de preentrenamiento supervisado en RM. Se observa una elevada concordancia entre la máscara de referencia y la predicción generada por la Attention U-Net, consistente con los valores cuantitativos reportados en la Tabla I.




Figura 2. Ejemplo de segmentación correspondiente al conjunto de validación de RM durante la etapa de preentrenamiento supervisado. La línea magenta representa la anotación de referencia y la línea cian la predicción generada por el modelo.

El desempeño obtenido en RM permitió utilizar este modelo como punto de partida para la posterior adaptación al dominio de US.

V-B. Adaptación al Dominio de Ultrasonido

Luego del preentrenamiento en RM, se evaluaron distintas estrategias de adaptación hacia ultrasonido. Inicialmente se

probó una estrategia adversarial basada en DANN, con el objetivo de alinear las representaciones internas entre RM y US. Si bien esta configuración logró reducir la capacidad del discriminador para distinguir dominios, el desempeño de segmentación no superó al modelo base entrenado en RM.

Posteriormente se incorporó supervisión débil sobre ultrasonido mediante *bounding boxes*. Esta estrategia permitió guiar espacialmente la predicción del modelo en el dominio destino, sin asumir que toda la región rectangular correspondía a la lesión. La mejor configuración final utilizó la arquitectura Attention U-Net preentrenada en RM y una pérdida suave basada en *bounding boxes*, manteniendo desactivado el componente adversarial.

Cuadro II
DESEMPEÑO SOBRE ULTRASONIDO UTILIZANDO MÉTRICAS BASADAS EN BOUNDING BOXES.

Estrategia	bbox_in	Centroid	Score
DANN + bbox débil	0.4774	0.5438	–
Soft-bbox inicial	0.5430	0.5563	0.6742
Soft-bbox final	0.6409	0.7000	0.7541

La Figura 3 muestra una imagen de US junto con la *bounding box* original y su versión expandida (*overbbox*), utilizadas como referencia espacial durante la etapa de postprocesamiento. Estas regiones permiten orientar la selección de la componente más plausible sin imponer una segmentación rígida sobre la predicción.




Figura 3. Imagen de US con la *bounding box* original y la región expandida utilizada como referencia espacial durante la selección de la región candidata en la etapa de postprocesamiento.

La Figura 4 presenta el resultado obtenido después del postprocesamiento. Esta etapa elimina activaciones espurias y conserva la región conectada más consistente, produciendo una segmentación más compacta y anatómicamente plausible.

La mejor configuración final correspondió a la estrategia de supervisión débil basada en *bounding boxes*. Este modelo




Figura 4. Segmentación final obtenida tras el postprocesamiento de la predicción generada por el modelo adaptado al dominio de US.

alcanzó un *target score* de 0.7541, manteniendo simultáneamente un Dice de validación RM de 0.9075, un HD95 de 5.33 píxeles y una *Object Precision* de 0.8918. En el dominio US obtuvo un valor de *bbox_in* de 0.6409 y una proporción de centroides dentro de la anotación de 0.7000.

En conjunto, los resultados sugieren que la incorporación de supervisión débil mediante *bounding boxes* favoreció la adaptación al dominio US respecto a la estrategia adversarial pura. Aunque se observó una ligera disminución del desempeño sobre RM, el modelo logró una localización espacial más consistente de las regiones de interés en US, evidenciando una mejor transferencia de conocimiento entre modalidades. No obstante, la calidad de las segmentaciones continuó siendo variable entre estudios, reflejando la dificultad inherente de la adaptación entre modalidades y las limitaciones asociadas al uso de anotaciones débiles.

V-C. Interpretación de Resultados

Los resultados obtenidos sugieren que las representaciones morfológicas aprendidas a partir de imágenes de RM pueden transferirse parcialmente al dominio de ultrasonido mediante un esquema de Adaptación de Dominio Débilmente Supervisada. La incorporación de supervisión basada en *bounding boxes* permitió mejorar la localización espacial de las predicciones respecto a la estrategia adversarial pura, evidenciando una mejor correspondencia entre las regiones segmentadas y la ubicación aproximada de los miomas.

Sin embargo, la segmentación precisa de miomas en ultrasonido continúa siendo una tarea desafiante. A diferencia del dominio RM, donde se dispone de máscaras densas y estructuras anatómicas mejor definidas, las imágenes ecográficas presentan ruido speckle, bajo contraste y una elevada variabilidad en la apariencia de las lesiones. Asimismo, las anotaciones débiles utilizadas durante la adaptación proporcionan únicamente información aproximada sobre la localización del mioma, sin describir explícitamente sus contornos.

El análisis cualitativo de las predicciones mostró que el modelo fue capaz de aprender restricciones espaciales coherentes y localizar regiones candidatas dentro de las áreas anatómicamente relevantes. No obstante, la recuperación precisa de los contornos continuó siendo limitada, observándose con frecuencia predicciones fragmentadas o regiones segmentadas de menor tamaño que la lesión real. Este comportamiento es

consistente con la naturaleza de la supervisión disponible, ya que las *bounding boxes* aportan información sobre la ubicación de la lesión pero no sobre su forma exacta.

Durante el análisis visual también se observó que los errores más frecuentes ocurrieron en miomas de gran tamaño o con patrones de intensidad heterogéneos, donde los límites anatómicos resultan difíciles de distinguir. En contraste, los miomas más pequeños y con bordes relativamente definidos tendieron a producir segmentaciones más consistentes. La Figura 5 presenta un ejemplo representativo de un caso complejo correspondiente a un mioma de gran tamaño.




Figura 5. Ejemplo representativo de un caso complejo correspondiente a un mioma de gran tamaño. Las variaciones internas de intensidad y los límites difusos dificultan la delimitación precisa de la lesión, produciendo segmentaciones menos consistentes.

En conjunto, estos resultados indican que la estrategia propuesta resultó más efectiva para la localización de regiones compatibles con la lesión que para la recuperación exacta de sus contornos. Aun así, los hallazgos obtenidos respaldan el potencial de la Adaptación de Dominio Débilmente Supervisada como alternativa para aprovechar información anatómica proveniente de RM y reducir la dependencia de anotaciones densas en ultrasonido.

V-D. Limitaciones

Este trabajo presenta diversas limitaciones que deben considerarse al interpretar los resultados obtenidos.

En primer lugar, el dominio objetivo de ultrasonido no dispone de máscaras de segmentación píxel a píxel, sino únicamente de anotaciones basadas en *bounding boxes*. Como consecuencia, la evaluación sobre US se realizó mediante métricas indirectas de localización y consistencia espacial. Si bien estas métricas permiten estimar la calidad de las predicciones, no constituyen una medida directa de la precisión de segmentación.

En segundo lugar, el conjunto de datos de US utilizado en este trabajo fue reducido a 288 imágenes tras el proceso de selección y depuración manual. Esta limitación restringe la diversidad anatómica disponible para entrenamiento y evaluación, pudiendo afectar la capacidad de generalización del modelo.

Por otra parte, se observaron diferencias en la composición de ambos dominios. Mientras que el conjunto de RM incluía casos con múltiples miomas visibles en una misma imagen, el conjunto de US estuvo compuesto predominantemente por

lesiones individuales. Esta discrepancia puede introducir una fuente adicional de desplazamiento entre dominios, dificultando la transferencia de conocimiento y afectando la capacidad del modelo para generalizar a configuraciones anatómicas más complejas.

Asimismo, las imágenes de US presentaban una elevada heterogeneidad en términos de calidad visual, incluyendo textos superpuestos, marcadores, artefactos de adquisición, ruido speckle y regiones sin información anatómica relevante. Aunque se aplicaron técnicas de preprocesamiento e *inpainting*, estas características continúan representando una fuente potencial de error.

Otra limitación corresponde a la dependencia del postprocesamiento aplicado durante la inferencia. La eliminación de regiones espurias, las operaciones morfológicas y el uso de información derivada de las *bounding boxes* contribuyeron significativamente a la calidad final de las segmentaciones. Por lo tanto, parte del desempeño observado no depende exclusivamente de las predicciones generadas por la red neuronal.

Finalmente, el comportamiento del modelo mostró sensibilidad a ciertos parámetros empíricos, particularmente al umbral de binarización utilizado para convertir probabilidades en máscaras. Variaciones en este valor pueden modificar el tamaño y la forma de las regiones segmentadas, afectando tanto las métricas cuantitativas como la evaluación visual de los resultados.

Adicionalmente, no se realizó un análisis estratificado según el tipo de mioma o su clasificación clínica. En consecuencia, no fue posible determinar si determinadas configuraciones anatómicas presentan mayores dificultades de segmentación que otras ni evaluar el impacto de las características morfológicas de la lesión sobre el desempeño del modelo.

VI. CONCLUSIÓN

En este trabajo se presentó un enfoque de Adaptación de Dominio Débilmente Supervisada para la segmentación de miomas uterinos en imágenes de ultrasonido 2D, utilizando transferencia de conocimiento desde un dominio fuente de resonancia magnética completamente anotado hacia un dominio objetivo con anotaciones limitadas a *bounding boxes*. Para ello, se empleó una arquitectura Attention U-Net preentrenada sobre imágenes de RM y posteriormente adaptada mediante una estrategia de supervisión débil basada en restricciones espaciales.

Los resultados obtenidos sugieren que las representaciones morfológicas aprendidas en RM pueden contribuir a la localización de regiones anatómicamente plausibles en ultrasonido. La incorporación de supervisión débil permitió mejorar las métricas de localización respecto a estrategias basadas exclusivamente en adaptación adversarial, evidenciando una transferencia parcial de conocimiento entre modalidades.

No obstante, la recuperación precisa de los contornos continuó siendo un desafío debido a las diferencias existentes entre RM y ultrasonido, la presencia de ruido y artefactos ecográficos,

y la ausencia de máscaras densas en el dominio objetivo. En consecuencia, el enfoque propuesto resultó más efectivo para la localización aproximada de lesiones que para la segmentación precisa de sus límites.

A pesar de estas limitaciones, los hallazgos obtenidos sugieren que la Adaptación de Dominio Débilmente Supervisada constituye una alternativa prometedora para reducir la dependencia de anotaciones exhaustivas en imágenes médicas y aprovechar información anatómica proveniente de modalidades con mayor disponibilidad de etiquetas.

VI-A. Trabajos Futuros

Como líneas futuras de investigación se propone ampliar el conjunto de datos de ultrasonido mediante la incorporación de nuevas imágenes y anotaciones realizadas por especialistas clínicos. Asimismo, sería de interés evaluar estrategias más avanzadas de supervisión débil, incluyendo pseudoetiquetado iterativo y mecanismos de consistencia espacial.

También resultaría relevante investigar nuevas estrategias de adaptación y supervisión débil que permitan mejorar la transferencia de conocimiento entre resonancia magnética y ultrasonido. En particular, se plantea analizar hasta qué punto las representaciones morfológicas aprendidas en resonancia magnética pueden contribuir a recuperar contornos más precisos en ultrasonido, reduciendo la brecha observada entre la localización aproximada de la lesión y su segmentación detallada.

Finalmente, futuros estudios podrían investigar la influencia de la clasificación FIGO sobre el proceso de adaptación entre modalidades, analizando si ciertos tipos de miomas favorecen o dificultan la transferencia de conocimiento desde resonancia magnética hacia ultrasonido.

REFERENCIAS

- [1] H. Pan, M. Chen, W. Bai, B. Li, X. Zhao, M. Zhang, D. Zhang, Y. Li, H. Wang, H. Geng, W. Kong, C. Yin, L. Han, J. Lan, and T. Zhao, "Large-scale uterine myoma MRI dataset covering all FIGO types with pixel-level annotations," *Scientific Data*, vol. 11, no. 1, p. 171, 2024.
- [2] D. Day Baird, D. B. Dunson, M. C. Hill, D. Cousins, and J. M. Schectman, "High cumulative incidence of uterine leiomyoma in black and white women: Ultrasound evidence," *American Journal of Obstetrics and Gynecology*, vol. 188, no. 1, pp. 100–107, 2003.
- [3] M. Saxena, N. S. Chandel, and S. Sharma, "Prospective analytical study comparing diagnostic accuracy of TVS & MRI," *International Journal of Medical and Public Health*, vol. 15, no. 1, pp. 113–118, 2025.
- [4] M. Dueholm, E. Lundorf, E. S. Hansen, S. Ledertoug, and F. Olesen, "Accuracy of magnetic resonance imaging and transvaginal ultrasonography in the diagnosis, mapping, and measurement of uterine myomas," *American Journal of Obstetrics and Gynecology*, vol. 186, no. 3, pp. 409–415, mar 2002.
- [5] C. Zhang, H. Shu, G. Yang, F. Li, Y. Wen, Q. Zhang, J.-L. Dillenseger, and J.-L. Coatrieux, "Hifunet: multi-class segmentation of uterine regions from mr images using global convolutional networks for hifu surgery planning," *IEEE Transactions on Medical Imaging*, vol. 39, no. 11, pp. 3309–3320, 2020.
- [6] Y. Zhang, "A survey of unsupervised domain adaptation for visual recognition," *arXiv preprint arXiv:2112.06745*, 2021. [Online]. Available: <https://arxiv.org/abs/2112.06745>

- [7] T. Saleem and M. Yaqub, "Deep learning-based automated segmentation of uterine myomas," *arXiv preprint arXiv:2508.11010*, 08 2025. [Online]. Available: <https://doi.org/10.48550/arXiv.2508.11010>
- [8] H. Xu, Y. Yang, A. I. Aviles-Rivero, G. Yang, J. Qin, and L. Zhu, "HilbertMamba: Local-global reciprocal network for uterine fibroid segmentation in ultrasound videos," *arXiv preprint arXiv:2407.05703*, 2025. [Online]. Available: <https://arxiv.org/abs/2407.05703>
- [9] R. Inbaraj, Y. M. Mahaboob John, K. Murugan, and V. Vijayalakshmi, "Enhancing medical image classification with cross-dimensional transfer learning using deep learning," *Advances in Computational Design*, vol. 10, no. 4, pp. 389–404, 2025.
- [10] Y. Xu, M. Gong, S. Xie, and K. Batmanghelich, "Box-adapt: Domain-adaptive medical image segmentation using bounding box supervision," in *Proceedings of the 30th International Joint Conference on Artificial Intelligence (IJCAI)*, 2021, pp. 1196–1202.
- [11] L. Maier-Hein, A. Reinke, E. Christodoulou, B. Glocker, S. Speidel, A. Kopp-Schneider, K. Maier-Hein, M. D. Tizabi, S. Fuller, M. Azizian *et al.*, "Metrics reloaded: Pitfalls and recommendations for image analysis validation," *Nature Methods*, vol. 21, no. 2, pp. 171–183, 2024.
- [12] M. Toldo, A. Maracani, U. Michieli, and P. Zanuttigh, "Unsupervised domain adaptation in semantic segmentation: A review," *Technologies*, vol. 8, no. 2, p. 35, 2020. [Online]. Available: <https://doi.org/10.3390/technologies8020035>
- [13] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Springer International Publishing, 2015, pp. 234–241.
- [14] O. Oktay, J. Schlemper, L. Le Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert, "Attention U-Net: Learning where to look for the pancreas," *arXiv preprint arXiv:1804.03999*, 2018. [Online]. Available: <https://arxiv.org/abs/1804.03999>
- [15] S. Paul, Y.-H. Tsai, S. Schuler, A. K. Roy-Chowdhury, and M. Chandraker, "Domain adaptive semantic segmentation using weak labels," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2020. [Online]. Available: <http://www.nec-labs.com/~mas/WeakSegDA>
- [16] H. Pan, M. Chen, W. Bai, B. Li, X. Zhao, M. Zhang, D. Zhang, Y. Li, and H. Wang, "UMD: Uterine myoma MRI dataset," Figshare, V3, 2023. [Online]. Available: <https://doi.org/10.6084/m9.figshare.23541312.v3>
- [17] T. Yang, "Uterine fibroid ultrasound images, Versión 2," Mendeley Data, V2, 2023. [Online]. Available: <https://doi.org/10.17632/n2zcmcygpb.2>
- [18] M. Brett, C. Markiewicz, M. Hanke, M.-A. Côté, B. Cipollini, P. McCarthy *et al.*, "nipy/nibabel: NiBabel 3.2.1," 2020.
- [19] A. Telea, "An image inpainting technique based on the fast marching method," *Journal of Graphics Tools*, vol. 9, no. 1, pp. 25–36, 2004.